

E-Ticaret Verisi Üzerinde RFM Analizi ile Müşteri Segmentasyonu

Ahmet Erce Kıyar

ÖZET

Bu çalışmada, UCI Machine Learning Repository'den elde edilen ve 2010–2011 yılları arasında ait 541.909 işlem kaydını içeren E-Commerce Data (Online Retail Dataset) veri seti üzerinde RFM (Recency, Frequency, Monetary) analizi uygulanmıştır. Veri ön işleme aşamasında eksik müşteri kimlikleri, negatif miktarlar, sıfır fiyatlı kayıtlar ve tekrarlayan işlemler temizlenerek 387.841 kayıttan oluşan analiz veri seti elde edilmiştir. Her müşteri için Recency (son alışverişten geçen gün sayısı), Frequency (benzersiz sipariş sayısı) ve Monetary (toplam harcama tutarı) metrikleri hesaplanmış; ardından 1–5 arası quantile tabanlı skora ile müşteriler segmentlere ayrılmıştır. K-Means kümeleme algoritması, Elbow ve Silhouette yöntemleriyle optimal küme sayısı $k=3$ olarak belirlenmiş; müşteriler Platin, Altın ve Gümüş olarak isimlendirilmiştir. Aylık cohort analizi ile müşteri elde tutma oranları incelenmiş, Aralık 2010 cohort grubunun %36,6 ile en yüksek birinci ay elde tutma oranına sahip olduğu tespit edilmiştir. Çalışma bulguları, müşteri sayısının yalnızca %31'ini oluşturan Platin segmentinin toplam gelirin %79,9'unu yarattığını ortaya koyarak Pareto ilkesini doğrulamıştır.

Anahtar Kavramlar: RFM Analizi, Müşteri Segmentasyonu, K-Means Kümeleme, Cohort Analizi, E-Ticaret

1. GİRİŞ

E-ticaret sektörünün hızla büyümesiyle birlikte işletmeler, artan müşteri kitlelerini daha iyi anlama ve segmentlere ayırma ihtiyacı duymaktadır. Müşteri ilişkileri yönetimi (CRM) kapsamında müşterilerin davranışsal örüntüleri incelenerek hedefli pazarlama stratejileri geliştirilmesi, hem müşteri memnuniyetini artırmakta hem de işletmelerin kaynaklarını daha verimli kullanmasını sağlamaktadır. Bu bağlamda, mevcut müşterileri elde tutmanın yeni müşteri kazanmaya kıyasla çok daha düşük maliyetli olduğu bilinmektedir (Reichheld ve Schefter, 2000).

RFM (Recency, Frequency, Monetary) analizi, müşterilerin ne kadar yakın zamanda alışveriş yaptıklarını, ne sıklıkla işlem gerçekleştirdiklerini ve ne kadar harcadıklarını esas alarak segmentasyon yapan bir yöntemdir. Hughes (1994) tarafından geliştirilen bu yöntem, sade yapısı ve güçlü açıklayıcılığı sayesinde akademik ve ticari çevrelerde yaygın kullanım alanı bulmuştur. Günümüzde makine öğrenmesi algoritmalarıyla birleştirilerek daha gelişmiş segmentasyon modellerine dönüştürülmektedir (Kurtaran, 2022).

Bu çalışmanın temel amacı, gerçek bir e-ticaret platformundan elde edilen işlem verisi üzerinde RFM analizi ve K-Means kümeleme algoritmasını uygulayarak müşteri segmentlerini ortaya çıkarmak ve her segment için stratejik içgörüler üretmektir. Çalışma ayrıca cohort analizi aracılığıyla müşteri elde tutma oranlarını zaman ekseninde incelemektedir.

Çalışma kapsamında aşağıdaki beş temel iş sorusu yanıtlanacaktır:

- Müşteriler RFM metriklerine göre kaç farklı segmente ayrılabilir ve her segmentin karakteristik özellikleri nelerdir?
- Hangi müşteri segmenti toplam gelirin en büyük bölümünü oluşturmaktadır?
- Müşterilerin satın alma sıklığı ile toplam harcama arasında nasıl bir ilişki vardır?
- Son 90 gün içinde alışveriş yapmamış ancak daha önce yüksek harcama yapmış müşterilerin profili nedir?
- Potansiyel sadık müşterileri en değerli segmente dönüştürmek için hangi stratejiler önerilmelidir?

2. LİTERATÜR TARAMASI

RFM analizi literatürde müşteri segmentasyonunun en temel ve en yaygın kullanılan yöntemlerinden biri olarak öne çıkmaktadır. Hughes (1994), RFM metriklerinin doğrudan pazarlama kampanyalarında müşteri davranışını tahmin etmede güçlü bir araç olduğunu ilk kez sistematik biçimde ortaya koymuştur. Sonraki çalışmalarda bu üç metriğin birleşiminin, demografik değişkenler kullanılmadan bile müşteri yaşam boyu değerini (CLV) öngörmede yüksek başarı sağladığı gösterilmiştir.

Kümeleme yöntemleri açısından değerlendirildiğinde, K-Means algoritması RFM tabanlı segmentasyonda en sık tercih edilen yöntem olarak öne çıkmaktadır. Optimal

küme sayısını belirlemek için Elbow yöntemi ve Silhouette skorunun birlikte kullanılması, literatürde standart uygulama hâline gelmiştir (Kurtaran, 2022). Otelcilik, sağlık ve güzellik gibi farklı sektörlerde gerçekleştirilen çalışmalarda K-Means ile üç ila sekiz küme arasında değişen segmentasyon yapılarının oluşturulduğu görülmektedir.

Cohort analizi, RFM çalışmalarını tamamlayan önemli bir zaman serisi yöntemi olarak değerlendirilmektedir. Cohort gruplarının elde tutma oranları incelenerek işletmeler, hangi dönemlerde müşteri kaybının yoğunlaştığını ve hangi müşteri gruplarının zaman içinde daha sadık kaldığını belirleyebilmektedir. Kurtaran (2022), lastik sektöründe yürüttüğü çalışmada cohort analizinin RFM segmentasyonu ile birlikte kullanılmasının stratejik karar verme süreçlerine somut katkılar sunduğunu göstermiştir.

Müşteri yaşam boyu değeri (CLV) kavramı da RFM analizi ile güçlü bir ilişki içindedir. Yüksek RFM skoruna sahip müşteriler genellikle daha yüksek CLV değeri taşımakta; bu durum işletmelerin hangi segmentlere öncelikli yatırım yapması gerektiğine dair net bir çerçeve sunmaktadır. Literatürde ek parametreler (örneğin Count Item) eklense de RFM metriklerinin kendi başına yeterli açıklayıcılığa sahip olduğu defalarca teyit edilmiştir.

3. VERİ SETİ SEÇİMİ VE AÇIKLAMASI

3.1. Veri Setinin Kaynağı ve Kapsamı

Bu çalışmada UCI Machine Learning Repository tarafından kamuoyuyla paylaşılan E-Commerce Data (Online Retail Dataset) kullanılmıştır. İngiltere merkezli bir çevrimiçi hediyelik eşya mağazasının 1 Aralık 2010 – 9 Aralık 2011 tarihleri arasındaki gerçek işlem kayıtlarından oluşan veri seti, Kaggle platformu (<https://www.kaggle.com/datasets/carrie1/ecommerce-data>) üzerinden de erişilebilir durumdadır.

Veri seti 541.909 satır ve 8 sütundan oluşmaktadır. InvoiceNo (fatura numarası), StockCode (stok kodu), Description (ürün açıklaması), Quantity (adet), InvoiceDate (tarih), UnitPrice (birim fiyat, £), CustomerID (müşteri kimliği) ve Country (ülke) değişkenlerini içermektedir. RFM analizinin temel gereksinimleri olan müşteri kimliği, tarih ve finansal bilgiler bu veri setinde doğrudan mevcut olup ek türetme gerekmemektedir.

3.2. Veri Seti Sınırlılıkları

Veri setinin başlıca sınırlılıkları şu şekilde sıralanabilir: Yalnızca bir yıllık dönemi kapsamaması, mevsimsel örüntülerin tam olarak gözlemlenmesini kısıtlamaktadır. Müşteri tabanında hem bireysel hem toptan alıcıların bulunması, RFM skorlarının yorumlanmasını güçleştirmektedir. Bunun yanı sıra demografik bilgiler (yaş, cinsiyet, gelir) ve pazarlama temas noktaları veri setinde yer almamaktadır.

3.3. İş Problemi

Bu çalışmanın çözdüğü BI problemi şu şekilde tanımlanmaktadır: "Bir e-ticaret şirketi, müşterilerini satın alma davranışlarına göre segmentlere ayırarak her segment için özelleştirilmiş pazarlama stratejileri geliştirmek istemektedir. RFM analizi ve K-Means kümeleme kullanılarak müşteri segmentleri belirlenecek ve cohort analizi ile müşteri elde tutma örüntüleri ortaya konacaktır."

4. YÖNTEMBİLİM

4.1. CRISP-DM Çerçevesi

Çalışmada veri madenciliği projelerinde standart süreç modeli olarak kabul gören CRISP-DM (Cross Industry Standard Process for Data Mining) metodolojisi benimsenmiştir (Schröer ve ark., 2021). CRISP-DM; İş Anlayışı, Veriyi Anlama, Veri Hazırlama, Modelleme, Değerlendirme ve Dağıtım olmak üzere altı aşamadan oluşmaktadır. Bu çalışma kapsamında ilk beş aşama eksiksiz biçimde ele alınmıştır.

4.2. RFM Metriklerinin Tanımı

RFM analizi üç temel metriğe dayanmaktadır. Recency, referans tarihinden (10 Aralık 2011) müşterinin son alışveriş tarihine kadar geçen gün sayısıdır; düşük değer daha iyi olarak yorumlanır. Frequency, ilgili dönemde gerçekleştirilen benzersiz sipariş sayısını ifade etmektedir. Monetary ise müşterinin toplam harcama tutarını (£) göstermektedir. Her müşteri bu üç metrik üzerinden değerlendirilerek 1–5 arası quantile tabanlı skorlar almaktadır.

4.3. K-Means Kümeleme

Müşteri kümeleme aşamasında sklearn kütüphanesinin K-Means algoritması kullanılmıştır. Ölçek farklarını gidermek amacıyla Frequency ve Monetary değişkenlerine logaritmik dönüşüm ($\log_{10}$) uygulanmış, ardından StandardScaler ile z-skoru normalleştirilmesi yapılmıştır. Optimal küme sayısı, 2 ile 10 arasındaki k değerleri için Elbow (Dirsek) yöntemi ve Silhouette skoru hesaplanarak belirlenmiştir.

4.4. Cohort Analizi

Cohort analizi, ortak özellik taşıyan müşteri gruplarının zaman içindeki davranışlarını izlemek için kullanılmaktadır. Bu çalışmada her müşterinin ilk alışveriş ayı cohort grubu olarak tanımlanmış; sonraki aylarda o cohort grubundan aktif kalan müşteri oranı elde tutma oranı (retention rate) olarak hesaplanmıştır. Sonuçlar ısı haritası görselleştirilmesiyle sunulmuştur.

5. ANALİZ VE UYGULAMA

5.1. Veri Temizleme

Veri ön işleme aşaması altı sistematik adımda gerçekleştirilmiştir. İlk adımda CustomerID değeri eksik olan 135.080 kayıt (%24,9) veri setinden çıkarılmıştır; müşteri kimliği bilinmeden RFM hesaplaması yapılamayacağından bu kayıtların çıkarılması zorunludur. İkinci adımda negatif Quantity değerine sahip 8.905 satır iade işlemi olarak ayrı bir veri setine alınmıştır. Üçüncü adımda sıfır veya negatif UnitPrice içeren 40 kayıt silinmiştir. Dördüncü adımda 'C' önekiyle başlayan iptal faturaları analiz kapsamı dışında tutulmuştur. Beşinci adımda aynı InvoiceNo, StockCode ve CustomerID kombinasyonuna sahip 10.043 tekrarlayan kayıt kaldırılmıştır. Altıncı adımda aykırı değerler için Winsorization uygulanmış; Quantity %99 eşiği 120, UnitPrice %99 eşiği ise 14,95 £ olarak belirlenmiştir.

Adım	İşlem	Çıkarılan/Düzeltilen	Kalan Satır
1	Eksik CustomerID	135.080	406.829
2	Negatif Quantity (iade)	8.905	397.924
3	Sıfır/neg. UnitPrice	40	397.884
4	İptal faturaları ('C')	0	397.884
5	Duplicate kayıtlar	10.043	387.841
6	Winsorization (aykırı)	—	387.841


Tablo 1. Veri temizleme adımları ve etkileri.

5.2. Keşifsel Veri Analizi

5.2.1. RFM Metriklerinin Dağılımı

Temizleme sonrasında 4.338 benzersiz müşteriye ait RFM tablosu oluşturulmuştur. Recency ortancası 50 gün, Frequency ortancası 2 sipariş ve Monetary ortancası 641 £ olarak hesaplanmıştır. Tüm üç metrikte de dağılımın sağa çarpık olduğu, yani küçük bir müşteri grubunun aşırı yüksek değerlere sahip bulunduğu gözlemlenmiştir. Bu durum aykırı değerlerin varlığına ve Monetary ile Frequency değişkenleri için logaritmik dönüşümün gerekliliğine işaret etmektedir.


Şekil 3. R, F, M Metriklerinin Dağılımı



Şekil 1. Recency, Frequency ve Monetary metriklerinin dağılımı.

5.2.2. Müşteri Segment Dağılımı


Quantile tabanlı RFM skorlaması sonucunda müşteriler sekiz segmente ayrılmıştır. Şekil 2'de görüldüğü üzere en kalabalık segment 987 müşteriyle Pasif Müşteriler iken, en değerli segment 952 müşteriyle Şampiyonlar olarak öne çıkmaktadır.



Şekil 2. Müşteri segment dağılımı.

5.2.3. Gelir Dağılımı

Segmentlerin toplam gelire katkısı incelendiğinde Pareto ilkesinin güçlü biçimde geçerli olduğu görülmektedir. Şekil 3'te sunulduğu üzere, Şampiyonlar segmenti toplam gelirin %66,1'ini tek başına oluşturmaktadır. Sadık Müşteriler %14,9 ile ikinci sırada gelirirken, tüm kalan segmentler birlikte yalnızca %19'luk paya sahiptir.




Şekil 3. Segmentlerin toplam gelire katkısı.

5.2.4. Recency–Frequency İlişkisi

Şekil 4, müşterilerin Recency ve Frequency değerleri arasındaki ilişkiyi segment bazında ortaya koymaktadır. Şampiyonlar ve Sadık Müşteriler kümelerinin sol üst bölgede (düşük


Recency, yüksek Frequency) yoğunlaştığı, Kayıp Müşterilerin ise sağ alt köşeye (yüksek Recency, düşük Frequency) yerleştiği görülmektedir.



Şekil 4. Recency ve Frequency ilişkisi (segment bazlı).

5.2.5. RFM Skor Isı Haritası


Şekil 5'te R ve F skorlarının kombinasyonuna göre ortalama harcama tutarları gösterilmektedir. R=5 ve F=5 kombinasyonundaki müşterilerin (sol alt köşe, en açık renkli hücreler) diğer gruplara kıyasla belirgin biçimde daha yüksek Monetary değerine sahip olduğu anlaşılmaktadır.

Şekil 6. R ve F Skoru Kombinasyonuna Göre Ortalama Harcama (£)**Şekil 5. R-F skor kombinasyonuna göre ortalama harcama (£).**

5.3. K-Means Kümeleme

5.3.1. Optimal Küme Sayısı

Şekil 6'da Elbow ve Silhouette analizlerinin sonuçları birlikte sunulmaktadır. Elbow grafiğinde $k=3$ 'te inertia eğrisinin belirgin biçimde kırıldığı görülmektedir. Silhouette skoru da $k=3$ 'te en yüksek değere (0,4165) ulaşmaktadır. Her iki kriter ve örnek çalışmayla tutarlılık gözetilerek optimal küme sayısı $k=3$ olarak belirlenmiştir.


**Şekil 6. Elbow ve Silhouette analizleri ($k=2-10$).**

5.3.2. Küme Sonuçları


K-Means algoritması üç küme üretmiştir. Kümeler, ortalama RFM değerleri incelenerek sırasıyla Platin Müşteri, Altın Müşteri ve Gümüş Müşteri olarak isimlendirilmiştir. Tablo 2'de kümelerin temel özellikleri özetlenmektedir.

Küme	Müşteri Sayısı	Ort. Recency (gün)	Ort. Frequency	Ort. Monetary (£)	Gelir Payı
Platin Müşteri	1.335	30	9,8	4.555	%79,9
Altın Müşteri	2.022	54	2,0	578	%15,4
Gümüş Müşteri	981	255	1,4	367	%4,7

Tablo 2. K-Means küme özet istatistikleri.




Şekil 7. K-Means kümeleme sonucu (3 boyutlu görselleştirme).



Şekil 8. Kümelerin ortalama RFM değerleri.

Şekil 11. Küme Büyüklüğü ve Toplam Gelir




Şekil 9. Küme büyüklüğü ve toplam gelir karşılaştırması.


5.4. Cohort Analizi

Aylık cohort analizi, 13 farklı cohort grubunu kapsamaktadır. Şekil 10'da sunulan ısı haritasında yatay eksen ilk alışverişten geçen ay sayısını (0 = ilk ay), dikey eksen ise cohort grubunu (ilk alışveriş ayını) göstermektedir. Hücredeki değer, o cohort grubundan söz konusu ayda hâlâ aktif olan müşterilerin oranını yüzde olarak ifade etmektedir.

Şekil 12. Aylık Cohort Analizi — Müşteri Elde Tutma Oranı (%)



Şekil 10. Aylık cohort analizi — müşteri elde tutma oranı (%).



Şekil 11. Cohort gruplarının birinci ay elde tutma oranları.

Cohort analizine göre birinci ay ortalama elde tutma oranı %20,6'dır. Aralık 2010 cohort grubu %36,6 ile en yüksek birinci ay elde tutma oranına sahipken, Kasım 2011 grubu %11,1 ile en düşük orana sahiptir. Bu durum, veri setinin son döneminde işlem yapan müşterilerin henüz alışkanlık oluşturmamış yeni müşterilerden oluşmasıyla açıklanabilir.

6. SONUÇLAR VE ÖNERİLER

6.1. Temel Bulgular

Bu çalışma, E-Commerce veri seti üzerinde RFM analizi ve K-Means kümeleme yöntemlerinin birlikte uygulanmasıyla elde edilen kapsamlı bulguları sunmaktadır.

Temel sonuçlar şu şekilde özetlenebilir:

- Platin Müşteri segmenti, 4.338 müşteri içinden yalnızca 1.335 kişiyi (%31) kapsamakta ancak toplam gelirin %79,9'unu oluşturmaktadır. Bu güçlü Pareto yapısı, işletmenin pazarlama kaynaklarını bu segmente yoğunlaştırması gerektiğine işaret etmektedir.
- RFM skorlamasında 555 kodlu Şampiyonlar (350 müşteri) ve 111 kodlu Kayıp Müşteriler (185 müşteri) iki kutup noktasını oluşturmaktadır. Bu iki grup arasındaki davranışsal uçurum, segmentlerin anlamlı biçimde ayrıştığını kanıtlamaktadır.
- K-Means kümeleme, Elbow ve Silhouette analizleriyle desteklenen k=3 kümede anlamlı gruplar üretmiştir. Örnek çalışmalarla (Kurtaran, 2022) tutarlı olan bu sonuç, üç küme yapısının e-ticaret segmentasyonunda sağlam bir pratik kural olduğunu teyit etmektedir.
- Cohort analizi, müşteri kaybının ilk alışveriş ayının hemen ardından en yüksek düzeye ulaştığını göstermektedir. Ortalama birinci ay elde tutma oranının %20,6 olması, yeni müşteri onboarding sürecinin iyileştirilmesine yönelik stratejik bir fırsat sunmaktadır.

- Satın alma sıklığı ile toplam harcama arasında pozitif bir ilişki gözlemlenmiştir. Yüksek Frequency değerine sahip müşteriler, ortalamada çok daha yüksek Monetary değerleri sergilemektedir.

6.2. İş Soruları

Çalışma kapsamında belirlenen beş temel iş sorusuna elde edilen bulgular şu şekilde yanıt vermektedir:

- Müşteriler RFM skorları temelinde sekiz anlamlı segmente ayrılmış; K-Means ile Platin, Altın ve Gümüş olmak üzere üç küme oluşturulmuştur.
- Platin segment, toplam gelirin %79,9'unu oluşturan en değerli kitleyi temsil etmektedir.
- Frequency ve Monetary arasında güçlü pozitif bir ilişki mevcuttur; sık alışveriş yapan müşteriler çok daha yüksek toplam harcamaya sahiptir.
- Son 90 gün içinde alışveriş yapmayan, ancak daha önce yüksek harcama gerçekleştiren müşteriler Risk Altındakiler ve Kaybedilmek Üzere segmentlerinde yer almaktadır. Bu grubun potansiyel gelir kaybı önemli bir büyüklük taşımaktadır.
- Potansiyel Sadık Müşteriler segmentinin Platin segmentine dönüştürülmesi için kişiselleştirilmiş teklifler, sadakat programları ve proaktif iletişim kampanyaları önerilmektedir.

6.3. Stratejik Öneriler

Analiz bulgularına dayanarak işletme yöneticilerine yönelik aşağıdaki stratejik öneriler geliştirilmiştir:

- Platin Müşteriler için: VIP sadakat programları, erken erişim teklifleri ve özel müşteri temsilcisi atanması bu segmentin şirkete bağlılığını pekiştirecektir.
- Risk Altındaki Müşteriler için: Özel indirim ve kişiselleştirilmiş e-posta kampanyaları ile yeniden etkinleştirme stratejileri uygulanmalıdır.
- Yeni Müşteriler için: İlk alışverişin hemen ardından başlayan kapsamlı bir onboarding süreci, %20,6 olan birinci ay elde tutma oranını anlamlı ölçüde artırabilir.
- Kayıp Müşteriler için: Geri kazanım maliyetinin getiriye aşp aşmadığı değerlendirilerek seçici bir geri kazanım stratejisi benimsenmelidir.

6.4. Çalışmanın Sınırlılıkları ve Gelecek Çalışmalar

Bu çalışmanın başlıca sınırlılıkları şunlardır: Veri setinin yalnızca tek bir yıllık dönemi kapsamı ve demografik bilgi içermemesi, bulguların genellenebilirliğini kısıtlamaktadır. Ayrıca hiperparametre optimizasyonu sınırlı tutulmuş olup grid search veya Bayesian optimizasyon uygulanmamıştır.

Gelecek çalışmalar kapsamında BERT4Rec ve Transformer tabanlı mimari gibi derin öğrenme yöntemlerinin zamansal davranış modellemesinde kullanılması, GAN tabanlı

veri artırma ile sınıf dengesizliği probleminin ele alınması ve CLV tahminiyle RFM segmentasyonunun bütünleşik modellenmesi önerilebilir.

KAYNAKÇA

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. <https://doi.org/10.1145/2939672.2939785>

Chen, D. (2012). Online retail dataset [Veri seti]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5BW33>

Hughes, A. M. (1994). Strategic database marketing. Probus.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30, 3146–3154.

Kurtaran, G. D. (2022). RFM analizi ile müşteri segmentasyonu. YBS Ansiklopedi, 13(1). https://ybsansiklopedi.com/wp-content/uploads/2022/07/RFM_ANALYSIS_gizem.pdf

Reichheld, F. F., & Scheffer, P. (2000). E-loyalty: Your secret weapon on the web. Harvard Business Review, 78(4), 105–113.

Schröer, C., Kruse, F., & Gómez, J. M. (2021). A systematic literature review on applying CRISP-DM process model. Procedia Computer Science, 181, 526–534. <https://doi.org/10.1016/j.procs.2021.01.199>

EKLER

Ek A: Veri Temizleme ve RFM Hesaplama Kodu

Çalışmada kullanılan Python kodunun temel yapısı aşağıda özetlenmektedir. Tam kod ayrı bir Jupyter Notebook dosyası olarak teslim edilmektedir.

```
# Veri temizleme – temel adımlar

df_clean = df.dropna(subset=['CustomerID'])

df_clean = df_clean[df_clean['Quantity'] > 0]

df_clean = df_clean[df_clean['UnitPrice'] > 0]

df_clean = df_clean.drop_duplicates(['InvoiceNo', 'StockCode', 'CustomerID'])

# RFM hesaplama

rfm = df.groupby('CustomerID').agg(

    Recency=('InvoiceDate', lambda x: (REF-x.max()).days),

    Frequency=('InvoiceNo', 'nunique'),

    Monetary=('TotalPrice', 'sum')).reset_index()
```

Ek B: K-Means Küme Detayları

Tablo 3, K-Means algoritmasının ürettiği üç kümenin tam istatistiksel özetini sunmaktadır.

Küme	n	Ort. R	Med. R	Ort. F	Med. F	Ort. M (£)	Med. M (£)
Platin	1.335	30	21	9,8	7	4.555	2.700
Altın	2.022	54	38	2,0	2	578	432
Gümüş	981	255	267	1,4	1	367	285

Tablo 3. Küme istatistikleri (R=Recency gün, F=Frequency sipariş, M=Monetary £).